

アンサンブル学習に基づいた欠損値補完について

高良 流平[†] 齊藤 史哲[†]

[†] 青山学院大学理工学研究科 〒155-8366 東京都渋谷区渋谷 4-4-25

E-mail: [†]c5625282@aoyama.jp, ^{††}yamamoto@design.inf.shizuoka.ac.jp

あらまし これはアブストラクトです。300 字程度でまとめてください。

キーワード 情報検索, 情報の信憑性, ヒューマンファクター

1 はじめに

1.1 研究背景

近年, センシング技術や情報通信の発達により, 医療, アンケート調査, Iot センサ, 顧客属性や販売実績といったビジネスデータ, さらには製造業におけるプロセスデータなど, 様々な分野において大量かつ多量のデータを収集できるようになっている。これらのデータは, 診断支援, 品質推定, 需要予測, プロセス監視など多様な意思決定を支える基盤として活用されている。一方で, 現実の計測環境においては常に完全なデータが得られるとは限らず, 計測機器の誤作動や通信エラー, 人為的な誤入力などにより, データ中に欠損値が含まれる状況がしばしば発生する。例えば医療現場では, 電子カルテ, 検査データ, 生体信号などが診断支援や予後予測のために広く利用されているが, 患者ごとに実施される検査項目が異なることや, 時間的制約などの理由からすべての指標を一律に取得することが困難である。その結果, 測定タイミングの不規則性や長期追跡データにおける患者の離脱など, 多様な要因に起因する欠損が生じることが指摘されている。また, 製造業におけるプロセスデータにおいても, データ駆動型ソフトセンサが製品品質の推定やプロセス監視のために広く利用されている一方で, すべての測定点にセンサを設置することは経済的に困難であり, 高温・高圧環境におけるセンサの故障やドリフト, 保守作業による停止などによって欠損が発生することが報告されている [参考文献]。

このような欠損を含むデータをそのまま用いて分析や予測を行うと, 解析精度の低下や推定値の偏り, さらには欠損を含むサンプルの除外による有効サンプルの減少といった問題を引き起こす。したがって, 欠損値を適切に補完し, 元の情報をできる限り保持した上でデータを活用することは, 信頼性の高いデータ分析を実現する上で不可欠な前処理である。

1.2 既存の欠損値補完手法とその課題

欠損値補完の基本的な手法としては, 平均値補完やホットデック法などの単一代入法が広く用いられてきた。これらの手法は実装が容易で計算コストも低い一方で, データの背後に隠れるクラスタ構造や非線形性を考慮できず, サンプルのばらつきに強く影響されるという課題を抱えている。その結果, 補完

後のデータにおいて分散の過小評価や推定値の歪みが生じる可能性がある。こうした単一代入法の限界を補う枠組みとして, 多重代入法が提案されている。多重代入法は, 欠損値の不確実性を複数の補完結果として反映できる点で理論的に優れた手法であるが, 補完モデルの仮定や選択に強く依存するという課題が指摘されている。特に高次元データや複雑な非線形構造を持つデータに対しては, 適切なモデル設計が困難である。

このような背景から, 近年ではモデル依存性を低減しつつ, データ駆動的に欠損値を補完する機械学習に基づく手法が広く研究されている。代表的な手法として, 局所的な距離関係に基づいて補完を行う kNN 補完や, ランダムフォレストを用いた missForest が挙げられる。kNN は比較的単純な構造のデータに対して有効である一方, 高次元空間では距離尺度の信頼性が低下するという問題を抱えている。また, missForest は非線形性や特徴量間の相互作用をある程度捉えることが可能であり, 混合型データにも適用できる汎用性の高い手法である。しかし, すべての特徴量を一律に利用して学習を行うため, ノイズ的な特徴量や寄与の小さい特徴量が分割に含まれ, 予測精度が低下する場合がある。また, 欠損率が高い場合や, サンプル数に比べて特徴量数が多い場合には, 過学習や性能劣化が生じやすいという課題が指摘されている。

1.3 本研究の目的

本研究では, ランダムフォレストを用いた欠損値補完手法である missForest に着目し, その補完精度および安定性の向上を目的とする。missForest は非線形性や特徴量間の相互作用を捉えられる有効な手法である一方で, すべての特徴量を一律に利用して学習を行うため, ノイズ的な特徴量や寄与の小さい特徴量の影響を受けやすいという課題を抱えている。特に, 欠損率が高い場合や, サンプル数に対して特徴量数が多い状況では, 予測精度の低下や過学習が生じやすい。

そこで本研究では, 特徴量選択の観点を導入し, 複数の基準に基づいて有効な特徴量部分集合を構築した上で, それぞれに対してランダムフォレストによる補完モデルを学習する。さらに, 各補完モデルの汎化性能を反映する指標として, ランダムフォレストの外部誤差推定である OOB (Out-of-Bag) の決定係数 R^2 を用い, その値に応じて予測結果を加重平均することで, 補完結果を統合するアンサンブル手法を提案する。

このように, 特徴量選択によるノイズの抑制と, アンサンブ

ル学習による安定化を同時に図ることで、既存の missForest に比べて、より頑健で信頼性の高い欠損値補完を実現することを目指す。本研究では、UCI Machine Learning Repository や OpenML にて公開されている複数の公開データセットを用いた数値実験を通じて、提案手法の有効性を評価する。

2 関連研究

2.1 MissForest の概要

missForest は、ランダムフォレストを基盤とした反復型の欠損値補完手法であり、分布仮定を必要としない非パラメトリックな手法として提案されている。各変数を目的変数、残りの変数を説明変数とみなしてランダムフォレストを学習し、欠損部分を予測する操作を変数ごとに繰り返すことで、データ行列全体の欠損値を補完する枠組みを採用している。この反復的な学習・更新により、特徴量間の非線形な関係や相互作用を考慮した補完が可能である。

missForest の特徴として、連続変数とカテゴリ変数が混在するデータに適用可能である点や、補完精度の推定にランダムフォレストの OOB 誤差を利用できる点が挙げられる。OOB 誤差を用いることで、外部の検証用データを用いることなく、補完結果の誤差を近似的に評価できる。また、多数の決定木の予測結果を平均化するランダムフォレストの構造は、多重代入的な性質を内包していると整理されている。

原著論文およびその後の研究において、missForest は医療データや生物データをはじめとする実データを用いた実験により、他の欠損値補完手法と比較して安定した補完性能を示すことが報告されており、機械学習に基づく欠損値補完手法の代表的な手法として位置づけられている。一方で、高次元データにおいては、補完に寄与しない特徴量の影響を受けやすいことが指摘されており、特徴量の扱いに関して改良の余地があるとされている。

3 提案

3.1 手法の概要

本研究で提案する手法は、欠損を含む各特徴量を目的変数とし、残りの特徴量を説明変数としてランダムフォレストを学習するという点では missForest と同様である。しかし、従来の missForest がすべての特徴量を一律に利用するのに対し、提案法では複数の基準に基づいて有効性の高い特徴量部分集合を構築し、各部分集合ごとに独立したランダムフォレストを学習させる。

このように、特徴量の選択基準を複数導入することで、不要あるいはノイズ的な特徴量の影響を低減し、多様性を持つ補完モデルを構築することを目的とする。以降では、まず特徴量部分集合の構築方法について述べ、その後、複数の補完モデルを統合する手法について説明する。

3.2 複数基準に基づく特徴量部分集合の構築

3.2.1 特徴選択導入の動機

missForest では、各特徴量の補完において、当該特徴量を目的変数とし、残りのすべての特徴量を説明変数としてランダムフォレストを学習する。この枠組みは、特徴量間の非線形な関係や相互作用を捉えられる一方で、補完に寄与しない特徴量やノイズ的な特徴量が説明変数に含まれる場合、予測結果のばらつきや過学習を引き起こす可能性がある。特に、サンプル数に対して特徴量数が多い場合や、特徴量間の相関構造が複雑な場合には、こうした影響が顕在化しやすいと考えられる。

また、各特徴量の補完に寄与する説明変数は、補完対象となる特徴量ごとに異なると考えられるが、missForest ではこれらを区別せず一律に利用している。そのため、目的変数に対する寄与が小さい特徴量が含まれることで、補完精度の低下や結果の不安定化を招く可能性がある。以上の点から、補完に有効な特徴量を選択的に用いることで、不要な情報の影響を低減し、より頑健な補完を行うことが期待される。

3.2.2 特徴量部分集合の構築方針

特徴量の重要度や補完への寄与は、評価基準やデータ構造に依存して変化するため、単一の基準に基づいて特徴量を選択した場合、特定の構造に偏った特徴量集合が得られる可能性がある。その結果、データによっては補完精度が十分に向上しない場合も考えられる。

そこで本研究では、複数の特徴選択基準に基づいて、異なる特徴量部分集合を構築する。各基準により選択された特徴量部分集合ごとに、独立したランダムフォレストを学習することで、補完に有効な特徴量の捉え方に多様性を持たせる。このようにして得られた複数の補完モデルを用いることで、特定の基準に依存した偏りを緩和し、より安定した補完結果を得ることを目指す。

3.3 各特徴選択基準

本節では、前節で述べた方針に基づき、特徴量部分集合を構築するために用いる各特徴選択基準について具体的に説明する。本研究では、複数の観点から有効な説明変数を抽出するため、以下に示す基準に基づいて特徴量部分集合を構築する。以降、補完対象となる特徴量を X_s 、説明変数候補を $\{X_j \mid j \neq s\}$ とする。また、各特徴選択基準 m により得られる特徴量部分集合を $\mathcal{F}_s^{(m)}$ と表す。なお、本研究では連続変数のみを対象とするため、以下の重要度評価は回帰設定を前提とする。

3.3.1 全特徴量利用 (ALL)

比較の基準として、補完対象 X_s に対し、残りのすべての特徴量を説明変数として用いる部分集合を構築する。すなわち、

$$\mathcal{F}_s^{(\text{ALL})} = \{X_j \mid j \neq s\}$$

とする。この設定は、従来の missForest と同様に全特徴量を用いる場合に対応しており、提案法における内部的な比較の基準として位置づけられる。

3.3.2 Permutation Importance に基づく選択 (PERM)

Permutation Importance (PI) は、学習済みモデルにおい

て各特徴量の値をランダムに入れ替えた際の予測性能の低下量に基づいて重要度を評価する指標である。本研究では、補完対象 X_s を目的変数としてランダムフォレストを学習し、各説明変数候補に対する PI を算出する。得られた重要度に基づき、上位の特徴量からなる部分集合 $\mathcal{F}_s^{(\text{PERM})}$ を構築する。

3.3.3 Mean Decrease Impurity に基づく選択 (MDI)

Mean Decrease Impurity (MDI) は、決定木の分岐における不純度 (回帰では分散など) の減少量を、各特徴量について集計することで重要度を評価する指標である。本研究では、補完対象 X_s を目的変数として学習したランダムフォレストにおいて、説明変数候補の MDI を算出し、重要度が高い特徴量からなる部分集合 $\mathcal{F}_s^{(\text{MDI})}$ を構築する。

3.3.4 相関係数に基づく選択 (CORR)

単変量の関係に基づく基準として、補完対象 X_s と各説明変数候補 X_j の相関係数を用いる。具体的には、観測可能なサンプルに基づいて $|\text{corr}(X_s, X_j)|$ を算出し、値の大きい特徴量からなる部分集合 $\mathcal{F}_s^{(\text{CORR})}$ を構築する。

3.3.5 ランダム選択 (RANDOM)

重要度に依存しない多様性確保のため、説明変数候補 $\{X_j \mid j \neq s\}$ からランダムに特徴量を抽出し、部分集合 $\mathcal{F}_s^{(\text{RAND})}$ を構築する。この基準は、特定の重要度指標に基づく選択がデータ構造によって偏る可能性を緩和し、補完モデル群の多様性を確保することを目的とする。

3.3.6 部分集合サイズの扱い

特徴量部分集合のサイズ k は、補完に用いる情報量とモデルの複雑さのトレードオフに影響する。本研究では、PERM/MDI/CORR に基づく部分集合については、あらかじめ得た重要度順位に対し、Top-1 から Top- d までの候補を順に評価し、ランダムフォレストの OOB 指標が最大となる k を自動選択する (動的 k 選択)。一方、RANDOM などの基準については、特徴量数に対する比率 k_{ratio} に基づく既定のサイズを用いる。

3.4 特徴量部分集合ごとの補完モデル学習

本研究では、補完対象となる各特徴量を目的変数とし、前節までに構築した特徴量部分集合ごとに、独立したランダムフォレスト回帰モデルを学習する。すなわち、各特徴選択基準 m により得られる特徴量部分集合 $\mathcal{F}_s^{(m)}$ に対して、補完モデル $f_s^{(m)}(\cdot)$ を構築する。

モデル学習には、当該特徴量が観測されているサンプルのみを用いる。一方、説明変数に含まれる欠損値については、各特徴量の平均値による一次補完を行った後、ランダムフォレストを学習する。これにより、欠損を含むデータに対しても各特徴量部分集合に基づく補完モデルの構築を可能とする。

また、ランダムフォレストの学習過程においては、ブートストラップ標本に基づく OOB サンプルが自然に得られる。本研究では、この OOB サンプルを用いて各補完モデルの汎化性能を評価し、次節におけるアンサンブル統合のための指標として利用する。

3.5 OOB 指標に基づくアンサンブル統合

本研究では、前節までに構築した特徴量部分集合ごとに学習された複数のランダムフォレスト補完モデルを統合するため、OOB 指標に基づく重み付きアンサンブルを用いる。ランダムフォレストはブートストラップ標本を用いて学習されるため、各モデルに対して学習データとは独立な OOB サンプルを用いた汎化性能の推定が可能である。

補完対象となる特徴量 X_s に対し、特徴選択基準 m に基づいて学習された補完モデルを $f_s^{(m)}(\cdot)$ 、対応する OOB 指標を $w_s^{(m)}$ とする。本研究では、OOB 指標として決定係数 R^2 を用い、 $w_s^{(m)} < 0$ の場合には $w_s^{(m)} = 0$ とすることで、補完性能が低いモデルの影響を抑制する。

得られた重みは以下のように正規化される。

$$\tilde{w}_s^{(m)} = \frac{w_s^{(m)}}{\sum_{m'} w_s^{(m')}},$$

ただし、 $\sum_{m'} w_s^{(m')} = 0$ の場合には、すべてのモデルに等しい重みを割り当てる。

最終的な補完値は、各補完モデルの予測値の加重平均として求める。欠損しているサンプル i に対する X_s の補完値 $\hat{x}_{is}$ は、

$$\hat{x}_{is} = \sum_m \tilde{w}_s^{(m)} f_s^{(m)}(\mathbf{x}_{i,-s})$$

と定義される。ここで、 $\mathbf{x}_{i,-s}$ はサンプル i における補完対象以外の特徴量ベクトルを表す。

このように、OOB 指標を用いて各補完モデルを統合することで、特徴選択基準ごとの性能差を反映しつつ、単一の基準に依存しない安定した補完結果を得ることを目指す。

4 実 験

4.1 実験設定

実験の前処理として、全特徴量を標準化し、この標準化空間において欠損の導入および補完を行った。完全データに対し、セル単位の MCAR (Missing Completely At Random) で欠損を導入し、欠損率 $r_{\text{miss}} \in \{0.1, 0.3, 0.5\}$ とした。欠損セル数は $\lceil N d r_{\text{miss}} \rceil$ (N はサンプル数、 d は特徴量数) であり、位置は一様無作為に重複なしで選択した。また、各反復において全手法で同一の欠損位置を用いることで公平性を担保した。各欠損率につき 50 回の独立反復を実施し、毎反復で欠損位置を再サンプリングした。評価はすべて標準化空間において行い、欠損セルのみを対象とした平均二乗誤差 (MSE) を指標とした。表 1 は各手法・各欠損率における 50 回反復の平均 (標準偏差) である。

4.2 実験に用いたデータ

実験には、UCI Machine Learning Repository にて公開されているベンチマークデータを利用した。採用したデータセットは、“iris”、“wine”、“diabetes”である。ここでは上記のデータに対してクラスとして扱われるカテゴリカル変数を削除し、特徴量のみを用いて欠損補完精度を評価した。

4.3 実験結果

実験結果は表 1 に示すとおりである．表中の数値は各手法・各欠損率における 50 回反復の MSE の平均を表している．また，括弧内の数値は試行毎の MSE の標準偏差を示している．

iris では，欠損率が 0.1 および 0.3 で missForest が最良な結果を示し，提案手法も同等の精度を示した．一方，欠損率が 0.5 では kNN が最小となり，低次元データではユークリッド距離に基づく近傍探索が有効に働いたと考えられる．このことから，単純なデータ構造に対しては kNN や missForest と同等の性能を発揮しつつ，提案手法は過剰適応することなく安定した補完が可能であることが確認された．wine では，全欠損率で提案手法が最小誤差となり，優位性が示された．これは特徴量間の相関が比較的強い中規模データでは，特徴選択と OOB 重みによるアンサンブル効果が有効に機能した結果と考えられる．

diabetes では欠損率 0.1 の際に missForest が優れたが，0.3 と 0.5 では提案手法が最小誤差を示し，中程度の相関を持つデータに対しても有効性を確認できた．

表 1 提案法（RF-Ens）と既存補完手法の精度比較

data set	missing rate	mean	kNN($k=5$)	missForest	RF-Ens (proposed)
iris	0.1	1.022(0.017)	0.261(0.012)	0.235(0.014)	0.243(0.010)
	0.3	1.018(0.008)	0.430(0.011)	0.365(0.014)	0.369(0.010)
	0.5	1.023(0.001)	0.545(0.009)	0.609(0.016)	0.548(0.012)
wine	0.1	1.003(0.013)	0.528(0.011)	0.491(0.010)	0.488(0.010)
	0.3	1.014(0.007)	0.634(0.006)	0.591(0.006)	0.583(0.006)
	0.5	1.021(0.004)	0.812(0.005)	0.786(0.009)	0.726(0.005)
diabetes	0.1	1.016(0.010)	0.643(0.007)	0.510(0.006)	0.518(0.006)
	0.3	1.010(0.004)	0.834(0.004)	0.649(0.005)	0.632(0.004)
	0.5	1.008(0.003)	1.007(0.003)	0.855(0.005)	0.779(0.004)

5 まとめと考察

iris データセットのような小規模なデータセットでは，提案手法は既存法と同等の精度を維持した．一方で，中規模以上のデータセットにおいては，特徴量選択を導入することで欠損補完の精度改善が確認された．これは，ノイズ的あるいは寄与の小さい特徴量を含めずに学習することで，欠損位置の違いによる推定値のばらつきが抑制され，より安定した補完が可能となったためである．さらに，相関の強い特徴量を優先的に利用することで，欠損値を説明力の高い情報に基づいて推定できるようになった．このように，特徴量選択はモデルの安定性と汎化性能を高め，欠損補完における頑健性の向上に寄与したと考えられる．

6 おわりに

本研究ではアンサンブルベースの欠損補完方法の代表的手法である missForest との比較において特徴量選択を導入した．ベンチマークデータによる性能評価により改善が確認できた．

謝辞 本研究は科学研究費（基盤 C）23K04275 による支援を受けたものです．

文 献

[1] 高橋 将宣, 渡辺 美智子, 欠測データ処理 R による単一代入法と多重代入法, 共立出版, (2017).

[2] Stekhoven, D. J. and Bühlmann, P., MissForest: non-parametric missing value imputation for mixed-type data, Bioinformatics, Vol. 28, No. 1, pp. 112-118 (2012).